

扩散模型理论基础

热力学扩散, DDPM, DDIM, Flow Matching

01



1.2 贝叶斯定理

A, B 是两个随机事件, $P(A)$ 表示事件 A 发生的概率, $P(B|A)$ 表示 A 事件发生的情况下 B 事件发生的概率, 则贝叶斯定理如下:

$$P(A|B) = \frac{P(B|A) * P(A)}{P(B)}$$

$$P(A \cap B) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$$

$$\therefore P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)}$$



所谓的前向加乘也就退

$$x_1 = \sqrt{\beta_1} \cdot \epsilon_1 + \sqrt{1 - \beta_1} \cdot x_0$$

↓
样本点...
的高斯分布

↓
部分继承
上一个状态

$\beta_0 \rightarrow \beta_1 \rightarrow \dots \rightarrow \beta_T$: β_0 接近 0, β_T 接近 1, $\therefore$ 迭代在扩展越快

月就表示扩散系数
是事先定义好的常数

从具体现象点. 调研 →

由 $x_0 \rightarrow x_T$, 如何很快推导, 而不是一步步算.

答案: 正态分布的可加性

由:

$$x_t = \sqrt{1 - \alpha_t} * \epsilon_t + \sqrt{\alpha_t} * x_{t-1}$$
$$x_{t-1} = \sqrt{1 - \alpha_{t-1}} * \epsilon_{t-1} + \sqrt{\alpha_{t-1}} * x_{t-2}$$

把 x_{t-1} 代入到 x_t 中可以推导出:

$$x_t = \sqrt{1 - \alpha_t} * \epsilon_t + \sqrt{\alpha_t} * (\sqrt{1 - \alpha_{t-1}} * \epsilon_{t-1} + \sqrt{\alpha_{t-1}} * x_{t-2})$$
$$= \sqrt{a_t(1 - a_{t-1})} * \epsilon_{t-1} + \sqrt{1 - a_t} * \epsilon_t + \sqrt{a_t a_{t-1}} * x_{t-2}$$

其中: ϵ_{t-1} 和 ϵ_t 是两个随机噪声, 且两者是两个独立的随机变量。

打个比喻: 我们有一个骰子掷两次分别得到 ϵ_{t-1} 和 ϵ_t , 完全可以等效

于我们有两个骰子掷一次。即: 一个骰子掷两次的概率分布等同于两个骰子掷一次的概率分布, 所以, 如果我们知道两个骰子掷一次的概率分布, 然后进行一次采样即可。

由正态分布的基本性质可知:
 ϵ_t 和 ϵ_{t-1} 服从 $N(0, 1)$, 即: $\epsilon_t \sim N(0, 1), \epsilon_{t-1} \sim N(0, 1)$
可以推导出: $\sqrt{1 - a_t} * \epsilon_t \sim N(0, 1 - \alpha_t)$
 $\sqrt{a_t(1 - a_{t-1})} * \epsilon_{t-1} \sim N(0, a_t - a_t * a_{t-1}))$

从而推导出:

$$\triangle \sqrt{a_t(1 - a_{t-1})} * \epsilon_{t-1} + \sqrt{1 - a_t} * \epsilon_t \sim N(0, 1 - a_t * a_{t-1})$$

进而推导出:

$$x_t = \sqrt{1 - a_t * a_{t-1}} * \epsilon + \sqrt{a_t * a_{t-1}} * x_{t-2}, \text{ 其中: } \epsilon \sim N(0, 1 - a_t * a_{t-1})$$

有个计算公式, 然后
两个分布是
独立的, 所以不叠加方差

然后归纳法出 x_t 与 x_0 的关系.

$$x_t = \sqrt{1 - a_t a_{t-1} a_{t-2} \dots a_1} * \epsilon + \sqrt{a_t a_{t-1} a_{t-2} \dots a_1} * x_0$$

其中, $\epsilon \sim N(0, 1 - a_t a_{t-1} a_{t-2} \dots a_1)$

为了方便表示, 记: $\bar{a}_t = a_t a_{t-1} a_{t-2} \dots a_1$

则: $x_t = \sqrt{1 - \bar{a}_t} * \epsilon + \sqrt{\bar{a}_t} x_0$


每一步的 β 或者 α 依据什么
取值呢

且而 x_t 也可以写成概率
函数形式

不好理解就举具体例子.

$q_t, t=0 \dots T$ 或 $\beta_t, t=0 \dots T$ 都是预先没好的超参

扩散模型逐渐击败了生成对抗网络



Step1: 在神经网络中，输入 x_t 时刻图像，训练得到此图像相对于某个 x_0 原图加入的噪声 ϵ 。

Step2: 将噪声 ϵ 带入到 x_{t-1} 的概率密度函数 $P(x_{t-1}|x_t, x_0)$ 中；

Step3: 从 x_{t-1} 的概率密度函数 $P(x_{t-1}|x_t, x_0)$ 中随机采样，得到 x_{t-1} (即 $t-1$ 时刻对应的图像)；

Step4: 将 x_{t-1} 作为神经网络的输入，带入到 **Step1** 中，循环 **Step1 ~ Step3**，直到得到 x_0

1. 两种图片表示

1.1 图片矩阵表示



Diagram showing the conversion of a 32x32 pixel image into a matrix representation. The image is represented by a 32x32 matrix of pixel values. The matrix is shown with a dashed line indicating its dimensions (32x32).

88	89	92	...	111	109	107
90	91	94	...	112	111	109
91	93	95	...	116	114	111
...	...	...	...	...	...	...
91	92	94	...	37	28	17
89	91	93	...	47	24	13
88	90	91	...	39	17	10

32x32=1024个像素
每个像素值范围 [0,255]

归一化

$$\frac{x}{128} - 1$$



$x \in [0, 255]$

-0.31	-0.30	-0.28	...	-0.13	-0.15	-0.16
-0.30	-0.29	-0.27	...	-0.13	-0.13	-0.15
-0.29	-0.27	-0.26	...	-0.09	-0.11	-0.13
...	...	...	...	...	...	...
-0.29	-0.28	-0.27	...	-0.71	-0.78	-0.87
-0.30	-0.29	-0.27	...	-0.63	-0.81	-0.90
-0.31	-0.30	-0.29	...	-0.70	-0.87	-0.92

分256个级别 每个像素值范围 [-1,1]

先归到 [0,2] 里. 也就是最大是2. $\frac{256}{128} = 2$
减"1", 下移一位, 就归到了 [-1,1] 里.

一张 32x32 黑白图片

$$x = \begin{bmatrix} x_1 & \cdots & x_{32} \\ \vdots & \ddots & \vdots \\ x_{992} & \cdots & x_{1024} \end{bmatrix}$$

1.2 图片向量表示



一张 32x32 黑白图片

==

1024 维度向量空间的一个点

$$x = [x_1, x_2, \dots, x_{1024}]$$

↓
归一化

坐标



1024维空间, 总计 256^{1024} 个点

每个轴256个度量

偏256

偏128

偏0



1.3 两种图片生成思路

计算像素数值：

求解：一张猫图片的32x32个像素之间关联公式

$$\hat{y} = f(x_1, x_2, \dots, x_{1024})$$

32

-0.3	-0.3	...	-0.1	-0.2
-0.3	-0.3	...	-0.1	-0.1
...	...	...	...	...
-0.3	-0.3	...	-0.8	-0.9
-0.3	-0.3	...	-0.9	-0.9

32

根据像素矩阵
算特征值


图像是高维空间的一个点、噪声，猫狗... 会

在这个高维空间里聚类扩散模型即在噪声与具体图像之间走

计算空间分布：

求解：所有猫的图片组成的点的分布

$$\hat{y} \sim D(\mu, \sigma^2, \dots)$$



2. 扩散模型

2.1 扩散模型 Diffusion Model

扩散模型：模拟热力学扩散过程来构建的图片生成式神经网络模型。



2.2 图片扩散过程

通过对原图不断增加随机噪声，最终让图片变成纯噪声图片。



0 step

...



10 step

...




100 step

...



500 step

...



1000 step

3. 基本公式

3.1 热力学基本公式

1908, 朗之万动力方程 (SDE) :

$$dx = A(x, t) \cdot dt + B(x, t) \cdot dw \quad dw \sim N(0, dt)$$

描述一个具体的微观粒, 在一个很短时间段内产生的位移的距离。

确定性位移, $A(x, t)$ 为速度方式

随机位移, 噪声扩散方式

高斯分布, 随机

噪声的引入



方差为 dt
噪声强度与
时间成正比



$B(x, t) \cdot dw$: 随机性的扩散项。这才是主角。它把随机噪声 dw 按一定强度 $B(x, t)$ 加入到当前状态 x 中。这个项就是模拟“滴入墨水并扩散”的过程。

多维空间:

$$dx = A(x, t) \cdot dt + B(x, t) \cdot dw @ I$$

1024×1024 $1 \times 1024 \rightarrow 1024 \times 1$ 的 dx

矩阵乘法, 保证 $B(x, t)$ 只保留对称元素

$$dx = [x_1, x_2, \dots, x_{1024}] \rightarrow \text{一张 } 1024 \text{ 维的图片}$$

$$dw = [w_1, w_2, \dots, w_{1024}] \rightarrow \text{要加到每个像素上的噪声, 也就一个 } 1024 \text{ 维的图片}$$

$$I = \begin{bmatrix} 1 & & & & \\ & 1 & & & \\ & & \dots & & \\ & & & 1 & \\ & & & & 1 \end{bmatrix} \quad 1024 \times 1024$$


假设 $B(x, t)$ 对每个像素加噪声是独立的, 也就是 w , 只影响 x_i

3.2 图片扩散过程 – 朗之万运动

2. 图片为什么向“中心”移动？——前向过程的本质

前向加噪过程的最终目标，是让任何一张输入图片，都变成服从“标准正态分布”的随机噪声。

- 什么是“标准正态分布”？就是我们熟悉的钟形曲线。它的中心是0，方差是1。在1024维空间中，这就是一个以零向量为中心的“超球状”云团。
- “向中心移动”的真实含义：
 1. 均值归零：前向过程的设计，会逐步抹去原始图片的固有信息（即其独特的像素值结构）。这个“固有信息”可以理解为用户像素值的均值（或期望）。随着噪声加大，这个均值被逐渐拉向0。
 2. 方差固定：同时，过程会控制噪声的强度，使得最终输出的噪声图片，其每个像素值的方差都变为1。
 3. 变成标准正态样本：当一张图片的每个像素值都变成均值为0、方差为1的独立随机数时，这张图片在1024维空间中就成为了标准正态分布的一个随机样本点。



3.3 高斯分布（正态分布）

高斯分布：

$$x \sim N(\mu, \sigma^2)$$

标准高斯分布：

$$\frac{x - \mu}{\sigma} \sim N(0, 1)$$

高斯分布线性转化：

$$x = \mu + \sigma \cdot \epsilon \quad \epsilon \sim N(0, 1)$$

$$x = \mu + n \quad n \sim N(0, \sigma^2)$$

也就是说：服从高斯分布的一个 x ，可视为均值加一个随机项。


这个线性变换会等于 $N(0, 1)$ 分布中的一个点...，假设是 ϵ ，故有 $\epsilon \sim N(0, 1)$

化分布为具体。

高斯分布的概率密度函数：

$$p(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$$

$$p(x|0, 1) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{x^2}{2}}$$



这是 $p(x)$ 的概率密度

独立高斯分布的可加性：

$$x \sim N(\mu_x, \sigma_x^2)$$

$$y \sim N(\mu_y, \sigma_y^2)$$

$$x + y \sim N(\mu_x + \mu_y, \sigma_x^2 + \sigma_y^2)$$

OK.

3.4 其他数学公式

贝叶斯公式: 已知B发生的前提下, 事件A发生的概率

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)} \longrightarrow p(A|B) = \frac{p(B|A) \cdot p(A)}{p(B)}$$

$$P(AB) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$$

$$\therefore P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(B) \cdot P(A|B)}{P(A)}$$

欧拉近似法:

$$\frac{dx}{dt} = f(x, t) \quad x_i = x_{i-1} + \int_{t=t_{i-1}}^{t_{i-1}+\Delta t} f(x, t) \approx x_{i-1} + \Delta t \cdot f(x_{i-1}, t_{i-1})$$

导数是这个 $\hookrightarrow$ 上一个点基础 $\hookrightarrow$ 由此近似 $\hookrightarrow$ 变化率

时间间隔

泰勒展开式:

$$f(x) \approx f(a) + \frac{f'(a)}{1!} (x-a) + \frac{f''(a)}{2!} (x-a)^2 + \dots + \frac{f^{(n)}(a)}{n!} (x-a)^n$$

4. 使用非平衡热力学的深度无监督学习

Deep Unsupervised Learning using Nonequilibrium Thermodynamics

2015, 索尔 – 迪克斯坦森 (Sohl - Dickstein)

4.1 热力学到神经网络

朗之万公式

$$dx = A(x, t) \cdot dt + B(x, t) \cdot dw$$

$$dw \sim N(0, dt)$$

$$A(x, t) = -\frac{1}{2}\beta(t) \cdot x$$

→ A是确定性部分, 把它定下来

$$B(x, t) = \sqrt{\beta(t)}$$

$$T = 1000 \quad \Delta t = \frac{1}{T} = 0.001 \text{ 化连续为离散}$$

$$\beta(t) = 10 \cdot t$$

$$t_{i-1} = [\frac{1}{1000}, \dots, \frac{1000}{1000}] \quad i \in [1, 1000] \rightarrow \text{共1000个时间步}$$

$$\beta(t_{i-1}) = [0.01, \dots, 10] \rightarrow \text{某个时间步的瞬时速率}$$

$$\beta_i \triangleq \beta(t_{i-1}) \cdot \Delta t = [0.00001, \dots, 0.01]$$

↓ 实际的变化量
β(t_{i-1}) 持除了 Δt

已知
可理解为噪声
扩散的速率
是瞬时速率

$$dx = -\frac{1}{2}\beta(t) \cdot x \cdot dt + \sqrt{\beta(t)} \cdot \sqrt{dt} \cdot \epsilon$$

$$dw \sim N(0, dt)$$

$$\therefore dw = \sqrt{dt} \cdot \epsilon$$

$$\frac{dw - 0}{\sqrt{dt}} \sim N(0, 1) = \epsilon$$

$$\epsilon \sim N(0, 1)$$

$$\epsilon \sim N(0, 1)$$

$$x_i - x_{i-1} = \Delta x_{i-1} = \int_{t=t_{i-1}}^{t_{i-1}+\Delta t} -\frac{1}{2}\beta(t) \cdot x \cdot dt + \int_{t=t_{i-1}}^{t_{i-1}+\Delta t} \sqrt{\beta(t)} \cdot dt \cdot \epsilon$$

两步之间的状态变化量

↓ 直接代入 t = t_{i-1}, dt = Δt

$$\approx -\frac{1}{2}\beta(t_{i-1}) \cdot x_{i-1} \cdot \Delta t + \sqrt{\beta(t_{i-1}) \cdot \Delta t} \cdot \epsilon_{i-1}$$

$$= -\frac{1}{2}\beta_i \cdot x_{i-1} + \sqrt{\beta_i} \cdot \epsilon_{i-1}$$

欧拉近似

用一堆细长的矩形去近似一个曲边梯形的面积。

关键思想: 在非常短的一步时间 Δt 内, 我们认为系统参数 β(t) 和状态 x 都来不及变化, 可以近似看作常数。

$$x_i = \left(1 - \frac{1}{2}\beta_i\right) \cdot x_{i-1} + \sqrt{\beta_i} \cdot \epsilon_{i-1}$$

↓ 近似

$$\approx \sqrt{1 - \beta_i} \cdot x_{i-1} + \sqrt{\beta_i} \cdot \epsilon_{i-1}$$

泰勒展开式

→ 最终结果

推出了这一步状态与上一次状态的关系。

4.2 前向单步加噪 $p(x_i|x_{i-1})$ 由这一步的加噪状态得到下一步的加噪状态.

$$\begin{cases} x_i = \sqrt{1 - \beta_i} \cdot x_{i-1} + \sqrt{\beta_i} \cdot \epsilon_{i-1} \\ a_i = 1 - \beta_i = [0.99999, \dots, 0.99] \end{cases}$$

是一个取值, 符合 $N(0,1)$
往大了说就是一个集合.
 β_i 是单位时间 Δt 内的变化量

ϵ_{i-1} 是一个随机变量服从 $N(0,1)$

x_i 的随机性完全来自 ϵ_{i-1} , 其必然也是一个


$$\begin{cases} x_i = \sqrt{a_i} \cdot x_{i-1} + \sqrt{1 - a_i} \cdot \epsilon_{i-1} \\ p(x_i|x_{i-1}) \sim N(\sqrt{a_i} \cdot x_{i-1}, 1 - a_i) \end{cases}$$

概率分布

高斯分布的性质:
一个确定值加上一个
高斯变量结果仍然服从
高斯分布

新分布的均值
与方差有联系.

由于 ϵ_{i-1} 的存在, 得到的是一个集合
采样后精确



4.3 前向累计加噪 $p(x_i|x_0)$

$$\left\{ \begin{array}{l} x_i = \sqrt{a_i} \cdot x_{i-1} + \sqrt{1-a_i} \cdot \epsilon_{i-1} \\ p(x_i|x_{i-1}) \sim N(\sqrt{a_i} \cdot x_{i-1}, 1-a_i) \\ \bar{a}_i = \prod_{n=1}^i a_n = a_1 \cdot a_2 \cdot \dots \cdot a_i = [0.99999, \dots, 0] \end{array} \right.$$



$$\left\{ \begin{array}{l} x_i = \sqrt{\bar{a}_i} \cdot x_0 + \sqrt{1-\bar{a}_i} \cdot \underline{\epsilon}_i \\ p(x_i|x_0) \sim N(\sqrt{\bar{a}_i} \cdot x_0, 1-\bar{a}_i) \end{array} \right.$$

$$x_i = \sqrt{a_i} \cdot x_{i-1} + \sqrt{1-a_i} \cdot \epsilon_{i-1}$$

其中 $\epsilon_{i-1} \sim N(0, 1)$ (标准正态, 方差为1)。

给定 x_{i-1} 时, x_i 是正态变量的线性变换 (x_{i-1} 是已知常数, ϵ_{i-1} 是正态噪声)。根据高斯分布的“线性不变性”:

• 若 $Y = kX + b$, 且 $X \sim N(\mu, \sigma^2)$, 则 $Y \sim N(k\mu + b, k^2\sigma^2)$ 。

因此, x_i 的条件分布为:

$$p(x_i|x_{i-1}) \sim N(\sqrt{a_i} \cdot x_{i-1}, 1-a_i)$$

原因二: 构建完整的马尔可夫链

写成条件概率的形式, 明确地指出这个过程是一个马尔可夫链: 每一步的状态 x_i 只依赖于前一步的状态 x_{i-1} , 与更早的历史无关。这极大简化了模型的数学处理。整个前向过程的联合分布可以分解为一系列条件概率的连乘:

$$p(x_{0:T}) = p(x_0) \cdot p(x_1|x_0) \cdot p(x_2|x_1) \cdot \dots \cdot p(x_T|x_{T-1})$$

这个优雅的分解形式是后续推导反向过程的起点。

$$\begin{aligned} x_i &= \sqrt{a_i} \cdot (\overbrace{\sqrt{a_{i-1}} \cdot x_{i-2} + \sqrt{1-a_{i-1}} \cdot \epsilon_{i-2}}^{x_{i-1}}) + \sqrt{1-a_i} \cdot \epsilon_{i-1} \\ &= \sqrt{a_i} \cdot \sqrt{a_{i-1}} \cdot x_{i-2} + \underbrace{\sqrt{a_i} \cdot \sqrt{1-a_{i-1}} \cdot \epsilon_{i-2} + \sqrt{1-a_i} \cdot \epsilon_{i-1}}_{\text{独立高斯分布}} \\ &= \sqrt{a_i \cdot a_{i-1}} \cdot x_{i-2} + \sqrt{1-a_i \cdot a_{i-1}} \cdot \epsilon' \\ &\dots \\ &= \sqrt{a_i \cdot a_{i-1} \cdot \dots \cdot a_1} \cdot x_0 + \sqrt{1-a_i \cdot a_{i-1} \cdot \dots \cdot a_1} \cdot \underline{\epsilon}_i \\ &= \sqrt{\bar{a}_i} \cdot x_0 + \sqrt{1-\bar{a}_i} \cdot \underline{\epsilon}_i \quad \rightarrow \text{累计后的噪声项} \end{aligned}$$

3. 分析噪声项:

ϵ_0 和 ϵ_1 是独立的标准正态变量 (每一步噪声独立), 因此它们的线性组合仍为正态分布。

计算总方差 (独立变量方差相加, 因协方差为0):


$$\begin{aligned} \text{Var}(\sqrt{a_2(1-a_1)} \cdot \epsilon_0 + \sqrt{1-a_2} \cdot \epsilon_1) &= (\sqrt{a_2(1-a_1)})^2 \cdot \text{Var}(\epsilon_0) + (\sqrt{1-a_2})^2 \cdot \text{Var}(\epsilon_1) \\ &= a_2(1-a_1) + (1-a_2) \\ &= 1-a_1a_2 \end{aligned}$$

而均值由 x_0 的系数决定: $\sqrt{a_1a_2} \cdot x_0$ 。


4.4 前向累计加噪 $p(x_i|x_0)$

x_i 与 x_0 的关系, 由 x_0 由此推 x_i


$$\begin{cases} x_i = \sqrt{\bar{a}_i} \cdot x_0 + \sqrt{1 - \bar{a}_i} \cdot \epsilon_i \\ p(x_i|x_0) \sim N(\sqrt{\bar{a}_i} \cdot x_0, 1 - \bar{a}_i) \end{cases}$$




4.5 模型学什么?



$$p(x_i|x_{i-1}) \sim N(\sqrt{a_i} \cdot x_{i-1}, 1 - a_i) \quad x_i = \sqrt{a_i} \cdot x_{i-1} + \sqrt{1 - a_i} \cdot \epsilon_{i-1}$$



$$p(x_i|x_0) \sim N(\sqrt{\bar{a}_i} \cdot x_0, 1 - \bar{a}_i) \quad x_i = \sqrt{\bar{a}_i} \cdot x_0 + \sqrt{1 - \bar{a}_i} \cdot \epsilon_i$$



$$p(x_{i-1}|x_i) \rightarrow p(x_{i-1}|x_i, x_0) \sim ?$$

$$P(AB) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$$

$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(B) \cdot P(A|B)}{P(A)} \quad \triangleleft$$

4.6 反向单步去噪 $p(x_{i-1}|x_i, x_0)$

- 两个高斯分布的乘积仍是高斯分布（对应分子）。
- 高斯分布的条件概率仍是高斯分布（对应目标 $p(x_{i-1} | x_i, x_0)$ ）

$$x_i = \sqrt{\bar{a}_i} \cdot x_0 + \sqrt{1 - \bar{a}_i} \cdot \underline{\epsilon_i} \rightarrow \text{前向累计加噪}$$

$$p(x_i|x_0) \sim N(\sqrt{\bar{a}_i} \cdot x_0, 1 - \bar{a}_i)$$

$$x_{i-1} = \sqrt{\bar{a}_{i-1}} \cdot x_0 + \sqrt{1 - \bar{a}_{i-1}} \cdot \underline{\epsilon_{i-1}} \quad \checkmark$$

$$p(x_{i-1}|x_0) \sim N(\sqrt{\bar{a}_{i-1}} \cdot x_0, 1 - \bar{a}_{i-1}) \quad \checkmark$$

$$x_i = \sqrt{a_i} \cdot x_{i-1} + \sqrt{1 - a_i} \cdot \epsilon_i \rightarrow \text{前向单步加噪}$$

$$p(x_i|x_{i-1}) \sim N(\sqrt{a_i} \cdot x_{i-1}, 1 - a_i) \quad \checkmark$$



$$x_{i-1} = \frac{\sqrt{a_i}(1 - \bar{a}_{i-1})}{1 - \bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-1}}\beta_i}{1 - \bar{a}_i} \cdot x_0 + \sqrt{\beta_i \cdot \frac{1 - \bar{a}_{i-1}}{1 - \bar{a}_i}} \cdot \tilde{\epsilon}_{i-1}$$

$$p(x_{i-1}|x_i, x_0) \sim N\left(\frac{\sqrt{a_i}(1 - \bar{a}_{i-1})}{1 - \bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-1}}\beta_i}{1 - \bar{a}_i} \cdot x_0, \beta_i \cdot \frac{1 - \bar{a}_{i-1}}{1 - \bar{a}_i}\right)$$



(即已知当前状态 x_i 和初始数据 x_0 ，推断前一状态 x_{i-1} 的分布)

$$p(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad \left. \vphantom{p(x|\mu, \sigma^2)} \right\} \text{高斯分布概率密度函数}$$

$$p(x_{i-1}|x_i, x_0) = \frac{p(x_i|x_{i-1}, x_0) \cdot p(x_{i-1}|x_0)}{p(x_i|x_0)} \quad \left. \vphantom{p(x_{i-1}|x_i, x_0)} \right\} \text{贝叶斯公式}$$

$$p(x_{i-1}|x_i, x_0) = \frac{\left(\frac{1}{\sqrt{2\pi(1-a_i)}} \cdot e^{-\frac{(x_i - \sqrt{a_i}x_{i-1})^2}{2(1-a_i)}}\right) \cdot \left(\frac{1}{\sqrt{2\pi(1-\bar{a}_{i-1})}} \cdot e^{-\frac{(x_{i-1} - \sqrt{\bar{a}_{i-1}}x_0)^2}{2(1-\bar{a}_{i-1})}}\right)}{\frac{1}{\sqrt{2\pi(1-\bar{a}_i)}} \cdot e^{-\frac{(x_i - \sqrt{\bar{a}_i}x_0)^2}{2(1-\bar{a}_i)}}}$$

$$p(x_{i-1}|x_i, x_0) = \frac{1}{\sqrt{2\pi \cdot \left(\beta_i \cdot \frac{1 - \bar{a}_{i-1}}{1 - \bar{a}_i}\right)}} \cdot e^{-\frac{\left[x_{i-1} - \left(\frac{\sqrt{a_i}(1 - \bar{a}_{i-1})}{1 - \bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-1}}\beta_i}{1 - \bar{a}_i} \cdot x_0\right)\right]^2}{2\left(\beta_i \cdot \frac{1 - \bar{a}_{i-1}}{1 - \bar{a}_i}\right)}}$$

(1) 分析分子 $p(x_i \mid x_{i-1}, x_0) \cdot p(x_{i-1} \mid x_0)$

• $p(x_{i-1} \mid x_0)$ 是已知的先验高斯分布: $\mathcal{N}(\sqrt{\bar{a}_{i-1}} \cdot x_0, 1 - \bar{a}_{i-1})$ 。

• $p(x_i \mid x_{i-1}, x_0)$: 由于正向过程中 x_i 仅由 x_{i-1} 加噪生成 (与 x_0 无直接依赖, 给定 x_{i-1} 后 x_0 是冗余信息), 因此等价于 $p(x_i \mid x_{i-1})$, 即高斯分布 $\mathcal{N}(\sqrt{\bar{a}_i} \cdot x_{i-1}, 1 - \bar{a}_i)$ 。

(2) 分析分母 $p(x_i \mid x_0)$

分母是分子对 x_{i-1} 积分后的边缘概率, 由于分子是两个高斯分布的乘积, 其积分结果仍是高斯分布 (可通过联合高斯的边缘分布公式直接计算, 或利用高斯积分的性质)。

(3) 推导条件分布 $p(x_{i-1} \mid x_i, x_0)$ 的参数

高斯分布由其均值和方差完全确定。我们需要计算条件分布的均值 μ 和方差 Σ 。

对于二维高斯分布 (x_{i-1}, x_i) , 条件分布 $p(x_{i-1} \mid x_i)$ 的均值和方差可通过以下公式计算 (利用联合分布的协方差矩阵):

$$\begin{aligned}\mu_{x_{i-1}|x_i} &= \mu_{x_{i-1}} + \frac{\text{Cov}(x_{i-1}, x_i)}{\text{Var}(x_i)}(x_i - \mu_{x_i}) \\ \Sigma_{x_{i-1}|x_i} &= \text{Var}(x_{i-1}) - \frac{\text{Cov}(x_{i-1}, x_i)^2}{\text{Var}(x_i)}\end{aligned}$$

结合正向过程的参数 ($\bar{a}_i, \bar{a}_{i-1}$ 等), 代入后经过代数化简 (合并同类项、配平方等), 最终可得反向单步去噪的条件分布为:

$$p(x_{i-1} \mid x_i, x_0) \sim \mathcal{N}(\mu, \Sigma)$$

$$\begin{aligned}\text{其中: } \mu &= \frac{\sqrt{\bar{a}_i}(1 - \bar{a}_{i-1})}{1 - \bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-1}} \cdot (1 - \bar{a}_i)}{1 - \bar{a}_i} \cdot x_0 \\ \Sigma &= (1 - \bar{a}_{i-1}) \cdot \frac{1 - \bar{a}_i}{1 - \bar{a}_i} \cdot (\text{简化后}) = \beta_i \cdot \frac{1 - \bar{a}_{i-1}}{1 - \bar{a}_i} \quad (\text{令 } \beta_i = 1 - \bar{a}_i)\end{aligned}$$

$$p(x_{i-1}|x_i, x_0) = \frac{p(x_i|x_{i-1}, x_0) \cdot p(x_{i-1}|x_0)}{p(x_i|x_0)} \quad \left. \vphantom{\frac{p(x_i|x_{i-1}, x_0) \cdot p(x_{i-1}|x_0)}{p(x_i|x_0)}} \right\} \text{贝叶斯公式}$$

用定理证.

$$P(A|B, C) = \frac{P(A, B, C)}{P(B, C)} \longrightarrow \begin{cases} \bullet A = x_{i-1} \\ \bullet B = x_i \\ \bullet C = x_0 \end{cases}$$

∴

$$P(x_{i-1} \mid x_i, x_0) = \frac{P(x_{i-1}, x_i, x_0)}{P(x_i, x_0)}$$

由概率的链式法则

$$P(x_{i-1}, x_i, x_0) = P(x_i \mid x_{i-1}, x_0) \cdot P(x_{i-1} \mid x_0) \cdot P(x_0)$$

分母同理.


$$P(x_i, x_0) = P(x_i|x_0) \cdot P(x_0)$$

约掉 $P(x_0)$


4.7 反向单步去噪 $p(x_{i-1}|x_i, x_0)$

$$\left\{ \begin{aligned} x_{i-1} &= \frac{\sqrt{a_i}(1 - \bar{a}_{i-1})}{1 - \bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-1}}\beta_i}{1 - \bar{a}_i} \cdot x_0 + \sqrt{\beta_i \cdot \frac{1 - \bar{a}_{i-1}}{1 - \bar{a}_i}} \cdot \tilde{\epsilon}_{i-1} \\ p(x_{i-1}|x_i, x_0) &\sim N\left(\frac{\sqrt{a_i}(1 - \bar{a}_{i-1})}{1 - \bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-1}}\beta_i}{1 - \bar{a}_i} \cdot x_0, \beta_i \cdot \frac{1 - \bar{a}_{i-1}}{1 - \bar{a}_i}\right) \end{aligned} \right.$$


还是一个高斯分布噪声项吧，可能写错了。



4.8 训练前置计算




4.9 模型训练





4.10 模型训练示意

模型学习的概率分布:

$$p(x_{i-1}|x_i, x_0) \sim N(\mu_{\theta}, \sigma_{\theta}^2)$$



4.11 模型推理




把预测的噪声分布当真代入反向去噪。
再随机 Sample 出具体噪声。

4.12 模型推理示意

猫的图片生成模型:

$p(x_{i-1}|x_i, \hat{x}_0) \approx p(x_{i-1}|x_i, x_0)$

标签 $\approx$ 预测




5. 去噪扩散概率模型 DDPM

Denoising Diffusion Probabilistic Models

2020.6, 乔纳森·霍 (Jonathan Ho), 阿杰·贾恩 (Ajay Jain), 彼得·阿贝尔 (Pieter Abbeel)

5.1 DDPM 核心升级点



5.2 学习噪声

学习概率分布 $p(x_{i-1}|x_i, x_0)$

反向去噪的均值 方差

$$\mu_{i-1} = \frac{\sqrt{a_i}(1 - \bar{a}_{i-1})}{1 - \bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-1}}\beta_i}{1 - \bar{a}_i} \cdot x_0 \quad \Bigg| \quad \sigma_{i-1}^2 = \beta_i \cdot \frac{1 - \bar{a}_{i-1}}{1 - \bar{a}_i}$$

$x_i = \sqrt{\bar{a}_i} \cdot x_0 + \sqrt{1 - \bar{a}_i} \cdot \underline{\epsilon_i}$

x_0 $\underline{\epsilon_i}$

→ 前向累计加噪公式

VS


学习噪声 $\underline{\epsilon_i}$

$\underline{\epsilon_i}$


高斯分布线性转化: $x \sim N(\mu, \sigma^2) \longrightarrow \begin{cases} \epsilon \sim N(0,1) \\ x = \mu + \sigma \cdot \epsilon \end{cases}$

✓
何惠来

5.3 模型训练



5.4 模型训练示意




5.5 模型推理

3. 为什么DDPM（预测噪声）更流行？


在论文中发现，预测噪声比直接预测图像均值更稳定、更容易训练，效果也更好。原因在于：

1. 目标尺度稳定：无论 x_i 是哪个时间步的，要预测的噪声 ϵ 始终服从标准正态分布 $N(0, I)$ 。而直接预测的 μ ，其数值范围会随着时间步剧烈变化。
2. 任务更简单：网络只需要专注于识别和分离出“加进去的噪声”，这是一个相对更明确的任务。
3. 损失函数简单：MSE损失非常稳定，不容易出现梯度爆炸或消失的问题。

热力学模型去噪过程



DDPM 去噪过程



区别是预测在前向过程中加的噪声。
具测的是那一刻噪声的具体采样值。

- 预测分布：相当于让你猜“我撒盐的规律是什么？”（比如，平均撒多少克，波动范围多大）。
- DDPM（预测采样值）：相当于直接让你猜“我刚才那一勺，具体撒了多少克盐？”

5.6 反向单步去噪 $p(x_{i-1} | x_i, \underline{\epsilon_i})$

这是DDPM论文的精妙简化。虽然网络只预测了一个具体的噪声值 $\underline{\epsilon}$ ，但通过以下方式，它隐式地学习并确定了整个去噪分布：

1. 均值由预测的噪声决定：我们之前推导过，反向分布的均值 μ 可以通过公式用 x_i 和 $\underline{\epsilon_i}$ 计算出来：

$$\mu = \frac{1}{\sqrt{a_i}} \left(x_i - \frac{1-a_i}{\sqrt{1-a_i}} \underline{\epsilon_i} \right)$$

因此，预测了 $\underline{\epsilon_i}$ ，就等于预测了分布的均值 μ 。

2. 方差被固定或简化：DDPM发现，将反向分布的方差 σ^2 设置为一个与时间步 i 相关的固定值（由 β_i 决定），而不是让神经网络去预测，效果更好且更稳定。这样，整个分布的“形状”（方差）是预先知道的，只需要确定其“位置”（均值）即可。

反向单步去噪公式

$$x_{i-1} = \frac{\sqrt{a_i}(1-\bar{a}_{i-1})}{1-\bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-1}}\beta_i}{1-\bar{a}_i} \cdot x_0 + \sqrt{\beta_i \cdot \frac{1-\bar{a}_{i-1}}{1-\bar{a}_i}} \cdot \tilde{\epsilon}_{i-1}$$

$$p(x_{i-1} | x_i, x_0) \sim N\left(\frac{\sqrt{a_i}(1-\bar{a}_{i-1})}{1-\bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-1}}\beta_i}{1-\bar{a}_i} \cdot x_0, \beta_i \cdot \frac{1-\bar{a}_{i-1}}{1-\bar{a}_i}\right)$$

$$x_i = \sqrt{\bar{a}_i} \cdot x_0 + \sqrt{1-\bar{a}_i} \cdot \underline{\epsilon_i} \quad \text{前向累加加噪}$$

$$x_0 = \frac{1}{\sqrt{\bar{a}_i}} (x_i - \sqrt{1-\bar{a}_i} \cdot \underline{\epsilon_i})$$

初-末状态的关系

反向单步去噪代进前项累加加噪。

$$\left\{ \begin{aligned} x_{i-1} &= \underbrace{\frac{1}{\sqrt{a_i}} \left(x_i - \frac{1-a_i}{\sqrt{1-a_i}} \cdot \underline{\epsilon_i} \right)}_{\mu} + \underbrace{\sqrt{\beta_i \cdot \frac{1-\bar{a}_{i-1}}{1-\bar{a}_i}} \cdot \tilde{\epsilon}_{i-1}}_{\sigma} \\ p(x_{i-1} | x_i, \underline{\epsilon_i}) &\sim N\left(\frac{1}{\sqrt{a_i}} \left(x_i - \frac{1-a_i}{\sqrt{1-a_i}} \cdot \underline{\epsilon_i} \right), \beta_i \cdot \frac{1-\bar{a}_{i-1}}{1-\bar{a}_i}\right) \end{aligned} \right.$$

↓
化成了上一步状态与本步状态+噪声的关系。



一次推理的噪声值，怎么确定整个分布的均值？



正叫反向单步去噪.

5.7 模型推理

$$p(x_{i-1}|x_i, \underline{\epsilon_i}) \sim N(\frac{1}{\sqrt{\alpha_i}}(x_i - \frac{1 - \alpha_i}{\sqrt{1 - \bar{\alpha_i}}} \cdot \underline{\epsilon_i}), \beta_i \cdot \frac{1 - \bar{\alpha_{i-1}}}{1 - \bar{\alpha_i}})$$





$$\mu = \frac{1}{\sqrt{\alpha_i}} \left(x_i - \frac{1 - \alpha_i}{\sqrt{1 - \bar{\alpha_i}}} \hat{\epsilon}_i \right)$$

• 直观理解：从 x_i 中“减去”模型预测的噪声贡献 $(\frac{1 - \alpha_i}{\sqrt{1 - \bar{\alpha_i}}} \hat{\epsilon}_i)$ ，再通过 $\frac{1}{\sqrt{\alpha_i}}$ 缩放，得到 x_{i-1} 的“中心位置”（均值）。

5.8 模型推理示意

猫的图片生成模型：

$\hat{\epsilon}_i \approx \epsilon_i$




5.9 训练随机步骤


$$x_i = \sqrt{\bar{a}_i} \cdot x_0 + \sqrt{1 - \bar{a}_i} \cdot \underline{\epsilon}_i$$

前置计算

Random $i = n \in [1,4]$



模型训练



步骤4: 推导分布的方差

反向过程的方差需兼顾“前向的方差累积规律”和“模型训练的可控性”，题目中方差为：

$$\sigma^2 = \beta_i \cdot \frac{1 - \bar{\alpha}_{i-1}}{1 - \bar{\alpha}_i}$$

- β_i : 反向过程设定的“方差参数”（控制去噪时分布的“松紧度”，让生成图既不过于随机也不过于僵硬）；
- $\frac{1 - \bar{\alpha}_{i-1}}{1 - \bar{\alpha}_i}$: 方差调度因子，源于前向加噪的“累积方差关系”（ $\bar{\alpha}_i = \bar{\alpha}_{i-1} \cdot \alpha_i$ ，因此 $1 - \bar{\alpha}_i = (1 - \bar{\alpha}_{i-1}) \cdot (1 - \alpha_i)$ ，代入后可简化不同步长下的方差适配逻辑）。


6. 去噪扩散隐式模型 DDIM

Denoising Diffusion Implicit Models

2020.10, 宋家明 (Jiaming Song) 、 孟晨霖 (Chenlin Meng) 、 尔蒙教授 (Stefano Ermon)

6.1 DDIM 核心升级点

在不重新训练模型的前提下,大幅提升图像生成速度.




6.2 跳步推理示意

模型学习的概率分布：

$$p\left(x_{i-n}\middle|x_i, \hat{\epsilon}_i\right) \sim N\left(\hat{\mu}_{i-n}, \hat{\sigma}_{i-n}^2\right)$$

由本状态的噪声与状态直接推理若干步前的状态



6.3 反向跳步去噪 $p(x_{i-n}|x_i, x_0)$

时间点
定义不同
而已。

$$x_i = \sqrt{\bar{a}_i} \cdot x_0 + \sqrt{1 - \bar{a}_i} \cdot \epsilon_i \quad \text{前向累加, 加噪.}$$

$$p(x_i|x_0) \sim N(\sqrt{\bar{a}_T} \cdot x_0, 1 - \bar{a}_i)$$

没毛病

$$x_{i-n} = \sqrt{\bar{a}_{i-n}} \cdot x_0 + \sqrt{1 - \bar{a}_{i-n}} \cdot \epsilon_{i-n}$$

$$p(x_{i-n}|x_0) \sim N(\sqrt{\bar{a}_{i-n}} \cdot x_0, 1 - \bar{a}_{i-n})$$

$$x_i = \sqrt{\bar{a}_i} \cdot x_{i-1} + \sqrt{1 - \bar{a}_i} \cdot \epsilon_i$$

前向单步加噪

$$x_i = \sqrt{\frac{\bar{a}_i}{\bar{a}_{i-n}}} \cdot x_{i-n} + \sqrt{1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}} \cdot \epsilon'_{i-n}$$

$$p(x_i|x_{i-n}) \sim N\left(\sqrt{\frac{\bar{a}_i}{\bar{a}_{i-n}}} \cdot x_{i-n}, 1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}\right)$$

与前向
累加加噪
完全殊
途

跟达叔一起学习AI

$$p(x_{i-n}|x_i, x_0) = \frac{p(x_i|x_{i-n}, x_0) \cdot p(x_{i-n}|x_0)}{p(x_i|x_0)}$$

贝叶斯公式

OK

$$p(x_{i-n}|x_i, x_0) \sim N\left(\frac{\sqrt{\bar{a}_i}}{1 - \bar{a}_i} (1 - \bar{a}_{i-n}) \cdot x_i + \frac{\sqrt{\bar{a}_{i-n}} (1 - \frac{\bar{a}_i}{\bar{a}_{i-n}})}{1 - \bar{a}_i} \cdot x_0, (1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}) \cdot \frac{1 - \bar{a}_{i-n}}{1 - \bar{a}_i}\right)$$

$$x_{i-n} = \left(\frac{\sqrt{\bar{a}_i}}{1 - \bar{a}_i} (1 - \bar{a}_{i-n}) \cdot x_i + \frac{\sqrt{\bar{a}_{i-n}} (1 - \frac{\bar{a}_i}{\bar{a}_{i-n}})}{1 - \bar{a}_i} \cdot x_0 \right) + \sqrt{(1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}) \cdot \frac{1 - \bar{a}_{i-n}}{1 - \bar{a}_i}} \cdot \tilde{\epsilon}_{i-n}$$

6. 重参数化采样形式

$$x_{i-n} = \mu + \sigma \cdot \tilde{\epsilon}_{i-n}$$

· 物理意义: 为了从分布 $p(x_{i-n}|x_i, x_0)$ 中采样出具体的 x_{i-n} , 我们使用重参数化技巧。即: 计算出的均值 μ 加上一个随机噪声 $\sigma \cdot \tilde{\epsilon}_{i-n}$, 其中 $\tilde{\epsilon}_{i-n} \sim N(0, I)$ 。

$$p(x_{i-n}|x_i, x_0) \sim N\left(\frac{\sqrt{\bar{a}_i}(1 - \bar{a}_{i-1})}{1 - \bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-1}}\beta_i}{1 - \bar{a}_i} \cdot x_0, \beta_i \cdot \frac{1 - \bar{a}_{i-1}}{1 - \bar{a}_i}\right)$$

$n = 1$

- 物理意义: 这是DDIM最关键的公式。它表明, 从 x_{i-n} 到 x_i 的加噪过程, 可以跳过中间的 $n-1$ 步, 一步完成。
- 如何得来: 将公式1和公式2中的 x_0 消去, 即可得到 x_i 和 x_{i-n} 的直接关系。这证明多步扩散等价于一个方差更大的单步扩散。
- 关键变量:
 - $\sqrt{\frac{\bar{a}_i}{\bar{a}_{i-n}}}$ 是新的信号衰减系数。由于 $\bar{a}_i < \bar{a}_{i-n}$, 这个系数小于1。
 - ϵ'_{i-n} 是一个新的标准高斯噪声, 它“打包”了从第 $i-n$ 步到第 i 步所有中间步骤的噪声。

6.4 反向跳步去噪 $p(x_{i-n} | x_i, \underline{\epsilon}_i)$

$$p(x_{i-n} | x_i, x_0) \sim N\left(\frac{\sqrt{\bar{a}_i} (1 - \bar{a}_{i-n})}{1 - \bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-n}} (1 - \frac{\bar{a}_i}{\bar{a}_{i-n}})}{1 - \bar{a}_i} \cdot x_0, (1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}) \cdot \frac{1 - \bar{a}_{i-n}}{1 - \bar{a}_i}\right)$$

本就是一个概率分布，因印带了

$$x_{i-n} = \left(\frac{\sqrt{\bar{a}_i} (1 - \bar{a}_{i-n})}{1 - \bar{a}_i} \cdot x_i + \frac{\sqrt{\bar{a}_{i-n}} (1 - \frac{\bar{a}_i}{\bar{a}_{i-n}})}{1 - \bar{a}_i} \cdot x_0 \right) + \sqrt{(1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}) \cdot \frac{1 - \bar{a}_{i-n}}{1 - \bar{a}_i}} \cdot \tilde{\epsilon}_{i-n}$$

↗ $\tilde{\epsilon}_{i-n}$

$$x_0 = \frac{1}{\sqrt{\bar{a}_i}} (x_i - \sqrt{1 - \bar{a}_i} \cdot \underline{\epsilon}_i)$$

用预测噪声估计 x_0

$$x_{i-n} = \frac{\sqrt{\bar{a}_{i-n}}}{\sqrt{\bar{a}_i}} \left(x_i - \frac{1 - \bar{a}_i}{\sqrt{1 - \bar{a}_i}} \cdot \underline{\epsilon}_i \right) + \sqrt{(1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}) \cdot \frac{1 - \bar{a}_{i-n}}{1 - \bar{a}_i}} \cdot \tilde{\epsilon}_{i-n}$$

可能存在笔误



$$\begin{cases} n = 1 \\ p(x_{i-1} | x_i, \underline{\epsilon}_i) \sim N\left(\frac{1}{\sqrt{\bar{a}_i}} \left(x_i - \frac{1 - \bar{a}_i}{\sqrt{1 - \bar{a}_i}} \cdot \underline{\epsilon}_i\right), \beta_i \cdot \frac{1 - \bar{a}_{i-1}}{1 - \bar{a}_i}\right) \end{cases}$$

从已知当前状态和预测的噪声直接推理多步前的状态分布。

由此 x_{i-n} 可由 x_i 与预测的 $\underline{\epsilon}_i$ 得到

6.5 模型推理

$$p(x_{i-n}|x_i, \underline{\epsilon_i}) \sim N(\frac{\sqrt{\bar{a}_{i-n}}}{\sqrt{\bar{a}_i}}(x_i - \frac{1 - \bar{a}_i}{\sqrt{1 - \bar{a}_i}} \cdot \underline{\epsilon_i}), (1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}) \cdot \frac{1 - \bar{a}_{i-n}}{1 - \bar{a}_i})$$



6.6 随机推理 到 确定推理

$$\left\{ \begin{array}{l} x_{i-n} = \frac{\sqrt{\bar{a}_{i-n}}}{\sqrt{\bar{a}_i}} \left(x_i - \frac{1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}}{\sqrt{1 - \bar{a}_i}} \cdot \underline{\epsilon}_i \right) + \sqrt{\left(1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}\right) \cdot \frac{1 - \bar{a}_{i-n}}{1 - \bar{a}_i}} \cdot \tilde{\epsilon}_{i-n} \\ \odot = \underbrace{\left(1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}\right) \cdot \frac{1 - \bar{a}_{i-n}}{1 - \bar{a}_i}} \end{array} \right. \quad \begin{array}{l} \text{反向跳步去噪} \\ \text{都是关于常数项, 可表示为 } c. \end{array}$$

$$x_i = \sqrt{\bar{a}_i} \cdot x_0 + \sqrt{1 - \bar{a}_i} \cdot \underline{\epsilon}_i$$



$$x_{i-n} = \frac{\sqrt{\bar{a}_{i-n}}}{\sqrt{\bar{a}_i}} x_i + \left(\sqrt{1 - \bar{a}_{i-n}} - \odot - \sqrt{\frac{\bar{a}_{i-n}(1 - \bar{a}_i)}{\bar{a}_i}} \right) \cdot \underline{\epsilon}_i + \sqrt{\odot} \cdot \tilde{\epsilon}_{i-n} \quad \text{化简}$$

6.7 调节方程

就是打包带项, 加个缩放旋钮.

DDIM 调节方程: $c_i^2 = \eta^2 \cdot (1 - \frac{\bar{a}_i}{\bar{a}_{i-n}}) \cdot \frac{1 - \bar{a}_{i-n}}{1 - \bar{a}_i}$ $\longrightarrow$ $x_{i-n} = \frac{\sqrt{\bar{a}_{i-n}}}{\sqrt{\bar{a}_i}} x_i + \left(\sqrt{1 - \bar{a}_{i-n} - c^2} - \sqrt{\frac{\bar{a}_{i-n}(1 - \bar{a}_i)}{\bar{a}_i}} \right) \cdot \underline{\hat{\epsilon}_i} + c \cdot \tilde{\epsilon}_{i-n}$


$C_i^2 = \eta^2 \cdot 0 \rightarrow$ 就是带项.

{	$\eta = 0$	$\xrightarrow{\text{确定}}$	$x_{i-n} = \frac{\sqrt{\bar{a}_{i-n}}}{\sqrt{\bar{a}_i}} x_i + \left(\sqrt{1 - \bar{a}_{i-n}} - \sqrt{\frac{\bar{a}_{i-n}(1 - \bar{a}_i)}{\bar{a}_i}} \right) \cdot \underline{\hat{\epsilon}_i}$	确定噪声, 不加乘.
	$0 < \eta < 1$	$\xrightarrow{\text{随机} + \text{确定}}$	$x_{i-n} = \frac{\sqrt{\bar{a}_{i-n}}}{\sqrt{\bar{a}_i}} x_i + \left(\sqrt{1 - \bar{a}_{i-n} - c^2} - \sqrt{\frac{\bar{a}_{i-n}(1 - \bar{a}_i)}{\bar{a}_i}} \right) \cdot \underline{\hat{\epsilon}_i} + c \cdot \tilde{\epsilon}_{i-n}$	
	$\eta = 1$	$\xrightarrow{\text{随机}}$	$x_{i-n} = \frac{\sqrt{\bar{a}_{i-n}}}{\sqrt{\bar{a}_i}} x_i + \left(\sqrt{1 - \bar{a}_{i-n} - c^2} - \sqrt{\frac{\bar{a}_{i-n}(1 - \bar{a}_i)}{\bar{a}_i}} \right) \cdot \underline{\hat{\epsilon}_i} + c \cdot \tilde{\epsilon}_{i-n}$	

6.8 确定推理示意

调节方程:

$\eta = 0$




7. 用于生成建模的流匹配

Flow Matching for Generative Modeling

2022.09, 蒂姆·萨利曼斯 (Tim Salimans)、乔纳森·霍 (Jonathan Ho)

7.1 核心升级点

预测噪音
↓
预测速度向量



- DDIM 问：“要清除当前图片的噪音，我该加多少反向噪音？”
- 流匹配 问：“要将当前点变成目标图片，它下一步该向哪里移动？”

高维空间点的
移动问题。

维度	扩散模型 (DDIM)	流匹配 (Flow Matching)
预测目标	预测噪声 (Noise) (图中“预测噪音”)	预测速度向量 (Velocity Vector) (图中“预测速度向量”)
数学路径	非线性、概率性路径 (图中黑色实线箭头，为弯曲轨迹)	线性、确定性路径 (图中紫色虚线箭头，为直线轨迹)
理论框架	基于随机微分方程 (SDE)。过程被建模为带随机噪声的扩散，路径是曲折、不确定的。	基于常微分方程 (ODE)。过程被建模为沿着一个确定向量场的“流动”，路径是平滑、直接的。
直观比喻	“拆解-重建” 像把一幅画逐步弄脏成纯噪音，再学习如何一步步擦除噪音复原。路径如同在崎岖的山路中寻路返回。	“直接映射” 像在河流中放置一个小船，直接学习从起点到终点的最快、最直的洋流方向。路径如同在平静湖面上的直线划行。

7.2 模型训练

中间状态. $\rightarrow$ 初始噪声 $\rightarrow$ 猫

$$x_t = (1 - t) \cdot x_0 + t \cdot x_1 \quad 0 \leq t \leq 1$$

$$u_t = \frac{dx_t}{dt} = x_1 - x_0$$

$$T = 1000$$


$$\Delta t = \frac{1}{T} = \frac{1}{1000}$$

$$t = \left[\frac{0}{1000}, \frac{1}{1000}, \dots, \frac{1000}{1000} \right]$$

时间离散化
定义.

将时间与状态.

t, x_t



X

$Model$

$\hat{u}_t$

$Loss_t$

u_t

$\hat{Y}$

Y

3. 输出与损失计算 (Output $\hat{Y}$ & Loss):

- 模型预测输出 $\hat{Y}$: 即预测的速度 $v_{\theta}(x_t, t)$ 。
- 真实标签 Y : 就是前面计算的常数速度 $u_t = x_1 - x_0$ 。

中间态.

x_0

$x_{\frac{300}{1000}}$

$x_{\frac{400}{1000}}$

x_1



u_0

$u_{\frac{300}{1000}}$

$u_{\frac{400}{1000}}$

u_1

中间速度.

学的是速度向量.

单位时间, 状态之差就是速度

这部分定义了流匹配如何构造训练数据对 (x_t, u_t) 。

1. 线性插值路径 (关键公式)

$$x_t = (1 - t) \cdot x_0 + t \cdot x_1, \quad 0 \leq t \leq 1$$

- x_0 : 从简单先验分布（如标准高斯噪声）中采样的一个点。
- x_1 : 从真实数据分布（如图片数据集）中采样的一个数据点（如一张猫图）。
- t : 一个在 $[0, 1]$ 区间内均匀采样的时间变量。
- x_t : 在 t 时刻的中间状态。它是 x_0 和 x_1 的线性组合。
 - 当 $t=0$ 时, $x_t = x_0$ （纯噪声）。
 - 当 $t=1$ 时, $x_t = x_1$ （真实数据）。
 - 当 $t=0.5$ 时, x_t 是两者的中间混合状态。

物理意义：这条公式定义了一条从噪声 x_0 到数据 x_1 的直线路径。这是流匹配与扩散模型的根本区别——扩散模型的前向路径是随机的、非线性的。

2. 真实速度场 (目标标签)


$$u_t = \frac{dx_t}{dt} = x_1 - x_0$$

- 这是 x_t 对时间 t 的导数，即 x_t 在 t 时刻沿该直线运动的“真实速度”。
- 由于路径是直线，这个速度是一个常数向量 $(x_1 - x_0)$ ，不随时间 t 改变。
- u_t 就是模型要学习的“标准答案”。


7.3 模型推理

$$\left\{ \begin{array}{l} u_t = \frac{dx_t}{dt} = x_1 - x_0 \quad \text{两状态之间产生的速度} \\ x_{t+\Delta t} = x_t + \int_t^{t+\Delta t} (x_1 - x_0) \approx x_t + u_t \cdot \Delta t \quad \checkmark \\ \text{如何推算下一状态.} \end{array} \right.$$

欧拉近似.



7.6 推理示意图



从零学习扩散模型

跟达叔一起学习AI

讲师：达叔