

(1) 自监督学习预训练 从头开始训练。

(2) 与预训练对应的就是迁移学习, 用自己的任务语料对模型进行二次训练”
比如用官方的 `Yolo.pt` 再训

- 基于句子的前 n 个词来预测下一个词，因为输出依赖于过去和当前的输入，因此该任务被称为**因果语言建模** (causal language modeling)；

My

My

name

My

name

is

My

name

is

Sylvain

name

is

Sylvain

.

- 基于上下文（周围的词语）来预测句子中被遮盖掉的词语 (masked word)，因此该任务被称为**遮盖语言建模** (masked language modeling)。

My

[MASK]


is

Sylvain


.

↓

name




Transformer 结构




① 训练时所有输入一起给, 答案 mask 一个词一个词给? 预测时一个词一个词给?

② 如果输入一次性给, 预测时特征算一次就行? 训练时是不断算? 然后更新参数, 为提是输入还是一次性给.



(1) 位置编码




嵌入算法将词转为向量
 $x = [x_1, x_2, x_3, x_4]$ 一般是512维
 的向量列表, 基于训练数据
 中最长句子的长度
 position $[p_1, p_2, p_3, p_4]$ 与 x 同维

公式

$$PE(pos, 2i) = \sin(pos/10000^{2i/d_{model}})$$

$$PE(pos, 2i + 1) = \cos(pos/10000^{2i/d_{model}})$$

参考啥意思。





- 行是一个词的
位置编码

(2) 自注意力机制

Q, K, V 来源于同一个输入, 但通过不同的线性变换得到

- Q. query 查询向量, $X \cdot W^Q$, 当前词想找什么
- K. Key 键向量, $X \cdot W^K$, 当前词能回答什么问题, 词性, 语意角色等。
- V. Value 值向量, $X \cdot W^V$. 当前词包含信息, 真正的词的含意特征表示向量。


自注意机制可以使之能查看输入序列的其它位置, 从而更好的编码该单词。



加权之后的对应词的特征向量
融合了对应相关性的词的含意



(3)多头注意力机制

多头注意力 Multi-Head Attention 相当于几个不同的 self attention 单独的组成，以 $h=8$ 为例




问题一：为什么要分成多头处理？
回答：将一个单词映射在高维空间中，对于不同维空间都可以学到不同的特征。通过所有维空间得到一个向量，不如将其拆分成多个维度，通过多个维度得到多个向量，从而捕捉到更多的信息。论文(Attention Is All You Need)作者就将512维向量拆成8份，每64维得到一个向量，即上图我们看到的0~7的q/k/v，这样就可以让特征更丰富些。

然后将每个X的不同维的注意力的特征拼在一起所以要横着拼



(4)残差连接与归一化



残差连接 $y=f(x)+x$ ；避免了梯度消失, 因为对 x 求导总会有一个常数项

🔗 什么是“归一化” (Normalization)?

简单来说，归一化就是将一组数值进行“标准化处理”，使其具备统一的尺度和范围。

核心操作：对一组数据 $x_1, x_2, \dots, x_n$ ，计算其均值 μ 和标准差 σ ，然后进行线性变换：

$$\hat{x}_i = \frac{x_i - \mu}{\sigma}$$

这样处理后，数据的均值变为 0，方差变为 1。这个过程也被称为标准化 (Standardization)

为什么要这么做？

• 稳定训练：防止某些层的数值过大或过小，导致梯度爆炸或消失，让模型更容易收敛。

• 加速收敛：使不同特征处于相似的数值范围，优化器（如SGD）能更稳定、快速地工作

特性	层归一化 (LayerNorm)	批归一化 (BatchNorm)
计算维度	单个样本内部，跨特征维度计算。	单个特征通道内，跨批次样本计算。
核心思想	将每个样本的向量“拉直”后归一化。	将一批样本在同一特征上的值归一化。
依赖批次	不依赖 batch size，即使 batch size=1 也有效。	强依赖 batch size，小批次效果差。
适用场景	RNN、Transformer 等变长序列任务。	CNN 等固定结构的图像任务。

📖 层归一化 (LayerNorm) 详解

1. 计算过程

对于一个输入向量 $x = [x_1, x_2, \dots, x_d]$ （例如，一个词向量的768维表示），LayerNorm 的计算步骤如下：

1. 计算均值 μ 和方差 σ^2

$$\mu = \frac{1}{d} \sum_{i=1}^d x_i, \quad \sigma^2 = \frac{1}{d} \sum_{i=1}^d (x_i - \mu)^2$$

2. 标准化 (减均值，除标准差)

$$\hat{x}_i = \frac{x_i - \mu}{\sqrt{\sigma^2 + \epsilon}}$$

(ϵ 是一个极小常数，如 10^{-5} ，用于防止分母为0)

3. 仿射变换 (可学习的缩放与平移)

$$y_i = \gamma \cdot \hat{x}_i + \beta$$

其中， γ (gamma) 和 β (beta) 是与输入向量同维度的可学习参数。它们允许模型在归一化后的基础上，恢复或调整信息的表达

假设一个批次有2个样本，每个样本有3个特征： $x = [[1, 2, 3], [4, 5, 6]]$ 。

1. 计算均值与方差 (按列/特征计算)

- 特征1: $\mu_1 = (1 + 4)/2 = 2.5, \sigma_1^2 = [(1 - 2.5)^2 + (4 - 2.5)^2]/2 = 2.25$
- 特征2: $\mu_2 = (2 + 5)/2 = 3.5, \sigma_2^2 = [(2 - 3.5)^2 + (5 - 3.5)^2]/2 = 2.25$
- 特征3: $\mu_3 = (3 + 6)/2 = 4.5, \sigma_3^2 = [(3 - 4.5)^2 + (6 - 4.5)^2]/2 = 2.25$


2. 标准化与仿射变换

假设 $\gamma = [1, 1, 1], \beta = [0, 0, 0], \epsilon = 0$ ，对第一个样本 $[1, 2, 3]$ 进行变换：

- $y_1 = (1 - 2.5)/\sqrt{2.25} = -1$
- $y_2 = (2 - 3.5)/\sqrt{2.25} = -1$
- $y_3 = (3 - 4.5)/\sqrt{2.25} = -1$

该样本的输出为 $[-1, -1, -1]$ 。对第二个样本 $[4, 5, 6]$ 的变换结果为 $[1, 1, 1]$

15) 解码端



当前翻译和已翻译的前文之间的关系。

当前翻译和已编码的特征向量之间的关系。

两个全连接层


$$FFN(z) = \max(0, z \cdot w_1 + b_1) \cdot w_2 + b_2$$

ReLU 一层 二层

最终多头

拼接后的z与输入维度同,乘以W后也与输入维度同

传递的K,V维度由解码器请求决定




但每一次只能看到时刻t及之前的输入,故未来的要mask上
预测时输出当输入

解码端的输入是答案。

使之无穷大而 softmax 后 $Q \cdot K^T$ 值概率趋近于0

全流程推导



编码端

a	a_1	a_2	a_3	a_4	a_5	...	...
b	b_1	b_2	b_3	b_4	b_5	...	...
c	c_1	c_2	c_3	c_4	c_5	...	...
...							

加上对应位置编码

X 输入 10×512

8个多头注意力

$$W_{K1}, W_{Q1}, W_{V1} (512 \times 64) \rightarrow Z_1 \quad 10 \times 64$$

$$W_{K2}, W_{Q2}, W_{V2} (512 \times 64) \rightarrow Z_2 \quad 10 \times 64$$

注意力计算完后
立刻拼接

8个Z' 拼接成 Z'

$$Z' = \begin{bmatrix} 10 \times 64 & 10 \times 64 & 10 \times 64 & \dots & \dots \end{bmatrix}$$

10×512

残差连接与归一化

先相加

$$Z' = X + Z' \quad (10 \times 512)$$

再归一化

$$\mu = \frac{1}{512} (a_1 + a_2 + \dots + a_{512})$$

$$\sigma^2 = \frac{1}{512} \sum (a_i - \mu)^2$$

$$\hat{a}_i = \frac{a_i - \mu}{\sqrt{\sigma^2 + \epsilon}}$$

前向传播

$$FFN(Z) = \max(0, W_1 Z + b_1) \cdot W_2 + b_2$$

$$= Z \quad (10 \times 512)$$

尺寸与输入同

解码端，以训练时为例，输入维度必须与编码器输出维度一致，序列也就是词数可变

假如本条答案是5个 token (答案 token 可以不一致，因为只重复一样就行)。

(5 x 512)

				...
				...
				...
...	...	...	...	...
...	...	...	...	...

只需3个

mask, 给无意义。

mask是在自注意力中使用，并不是在位置编码之前。

第3个时间步

经过位置编码

$$5 \times 512$$

多头注意力机制

8个头

$$W_{Q,K,V}^1 (512 \times 64) \rightarrow \begin{cases} Q_1 \\ K_1 \\ V_1 \end{cases} \quad 5 \times 64$$

$$W_{Q,K,V}^2 (512 \times 64) \rightarrow \begin{cases} Q_2 \\ K_2 \\ V_2 \end{cases} \quad 5 \times 64$$

8个

8组

$$Q \quad 5 \times 64$$

a_1
a_2
a_3
a_4
a_5

$$K^T \quad 64 \times 5$$

k_1	k_2	k_3	k_4	k_5
-------	-------	-------	-------	-------

$$\frac{QK^T}{\sqrt{d}}$$

$a_1 k_1$	$a_1 k_2$	$a_1 k_3$	$a_1 k_4$	$a_1 k_5$
$a_2 k_1$	$a_2 k_2$	$a_2 k_3$	$a_2 k_4$	$a_2 k_5$
$a_3 k_1$	$a_3 k_2$	...	-	..
$a_4 k_1$	$a_4 k_2$	...	..	..
$a_5 k_1$	$a_5 k_2$	...	..	..


5x5 分数矩阵

此时加入mask.
即 $\frac{QK^T}{\sqrt{d}} + \text{mask}$
每个token只能看到自己及之前的token.
与自己位置有关. 故mask是一个固定的下三角

固定的mask

0	$-\infty$	$-\infty$	$-\infty$	$-\infty$
0	0	$-\infty$	$-\infty$	$-\infty$
0	0	0	$-\infty$	$-\infty$
0	0	0	0	$-\infty$
0	0	0	0	0


行 i (Q_i) 指着, 第 i 个 token 在看谁.
列 j (K_j) 被看, 第 j 个 token 在被第 i 个看



所以点乘也没问题 看 v_2 即可

$$Z_1 = A_{11} \cdot v_1 + A_{12} v_2 \dots$$

$$Z_2 = A_{21} \cdot v_1 + A_{22} v_2 \dots$$



mask指的是未来不被看 (K不被看).

mask 5x5

0	$-\infty$	$-\infty$	$-\infty$	$-\infty$
0	0	$-\infty$	$-\infty$	$-\infty$
0	0	0	$-\infty$	$-\infty$
0	0	0	0	$-\infty$
0	0	0	0	0

→ 第 i 个看不了 i 之后的

$\text{softmax}(A)$

按行做

$$\text{softmax}(A_{11}) = \frac{e^{A_{11}}}{e^{A_{11}} + e^{A_{12}} + \dots + e^{A_{15}}}$$

针对第3行有

$$\text{softmax}(A_{34}) = \frac{e^{-\infty}}{e^{q_{3k_1}} + e^{q_{3k_2}} + e^{q_{3k_3}} + e^{-\infty} + e^{-\infty}} = 0$$

∴ 对 A 不为0, 不然 $\frac{0}{0}$

$A = \text{score} + \text{mask}$

q_{1k_1}	$-\infty$	$-\infty$	$-\infty$	$-\infty$
q_{2k_1}	q_{2k_2}	$-\infty$	$-\infty$	$-\infty$
q_{3k_1}	q_{3k_2}	q_{3k_3}	$-\infty$	$-\infty$
q_{4k_1}	q_{4k_2}	q_{4k_3}	q_{4k_4}	$-\infty$
q_{5k_1}	q_{5k_2}	q_{5k_3}	q_{5k_4}	q_{5k_5}

